DOMAĆA ZADAĆA BR 2:

FRAN GALIĆ; 0036546889; Fran Galić

5.1

$X = \mathbb{R}^3$, $x \in X$

$\vec{w} = (-5, -4, 0, 3)$

$h(\vec{x}; \vec{w}) = f(\vec{w}^T \vec{x} + w_0)$

$f(x) = \begin{cases} 1, & w^T\vec{x} + w_0 \geq 0 \\ -1, & \text{INAČE} \end{cases}$

$\vec{x}, y = 1$

↳ BINARNI KLASIFIKACIJSKI PROBLEM

FUNKCIJA GUBITKA PERCEPTRONA:

$L(h(\vec{w}; \vec{x}), \vec{x}) = 1$

$\max(0, -(w^T\vec{x} + w_0) \cdot y)$

$d = ?$

POŠTO je POGREŠKA 1, ZNAMO DA je PRIMJER POGREŠNO KLASIFICIRAN,

ODNOSNO: $h(\vec{x}; \vec{w}) = -1$

$d = \frac{h(\vec{x}; \vec{w})}{\|\vec{w}\|_2 \to \text{BEZ } w_0} = \frac{-1}{\sqrt{(-4)^2 + 0^2 + 3^2}} = \frac{-1}{\sqrt{16+9}} = \frac{-1}{\sqrt{25}} = \boxed{\frac{-1}{5}}$

↳ Rj: $\boxed{A}$

↳ MODEL GA MORA KLASIFICIRATI KAO -1, POŠTO MU je PRAVA OZNAKA 1

↳ DODATNO: TO BI MOGLI IZRAČUNATI i SAMI $\vec{x}$ VIERUJATNO AKO BI HTJELI

PERCEPTRON DAJE POGREŠNU SAMO ZA POGREŠNO KLASIFICIRANE PRIMJERE
↳ TO je TRIK

5.2

$X \in \mathbb{R}^2$

$D = \{(\vec{x}^{(i)}, y^{(i)})\} = \{((\overset{x_1}{1}, \overset{x_2}{0}), +1), ((\overset{x_1}{2}, \overset{x_2}{-3}), -1), ((\overset{x_1}{2}, \overset{x_2}{5}), -1)\}$

① ② ③

↳ TRENIRAMO PERCEPTRON

$\Phi(x) = (1, x_1, x_2, x_1 x_2, \overset{\to \text{BITNO}}{x_1^2}, x_2^2)$

$\vec{w} = (1, 0, -1, -1, 3, 0)$

$E(\vec{w} | D) = ?$

$E(\vec{w} | D) = \frac{1}{N} \sum_{i=1}^{N} \max(0, -(\vec{w}^T \tilde{\Phi}(\vec{x})) \cdot y)$

$\boxed{E = 22} \to$ Rj: $\boxed{B}$

NETREBAMO DIJELITI SA $\frac{1}{N}$

① DALI DA ONDA PAMTIMO SAMO PO SAVIJENU NAD TROJKA DIJELIMO SA $\frac{1}{N}$ U KOJIM JE N (br. $\frac{1}{2}$)

↳ ZA PERCEPTRON NE DIJELIMO $\frac{1}{N}$ (JER MOŽEMO!)

$m(1) = 0$

↳ FULO SAM IZRAČUN

$m(2) = 2,2 \cdot 10^1 = 22$

$m(3) = \max(0, -2) = 0$

↳ RAČUNO SAM U HAL KULATORU $-(\vec{w}^T\vec{x}) \cdot y$ NA SVAKI PRIMJER, ako BI DOBIO 20, ONDA je REŽO, INAČE: $-(\vec{w}^T\vec{x}) \cdot y$

FRAN GALIĆ; 0036546889; Fran Galić

5.1

$$D = \{(\vec{x}^{(i)}, y^{(i)})\} = \{((-2,0),-1), ((-1,0),+1), ((1,0),+1), ((2,0),-1)\}$$

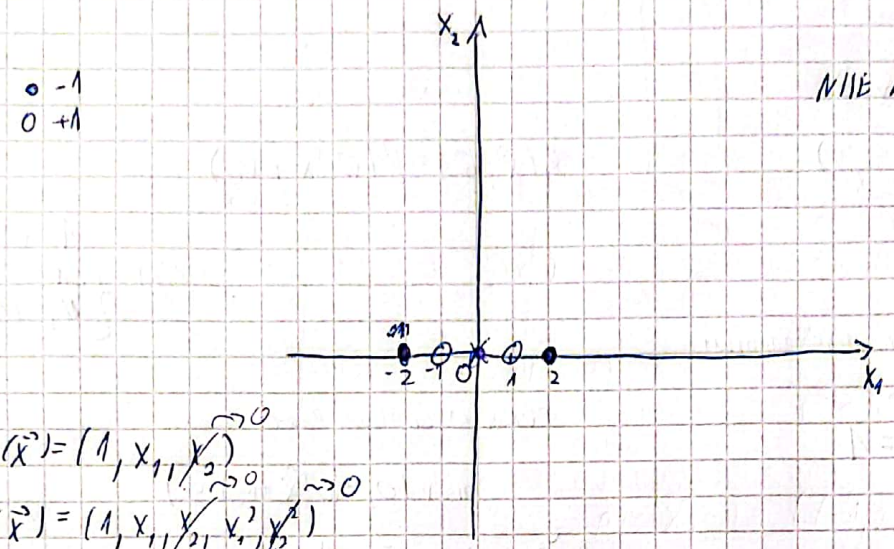

NIJE LINEARNO ODVOJIVO

$\Phi_0(\vec{x}) = (1, x_1, \cancel{x_2})$ $\rightsquigarrow 0$

$\Phi_1(\vec{x}) = (1, x_1, \cancel{x_2}, x_1^2, \cancel{x_2^2})$ $\rightsquigarrow 0$ $\rightsquigarrow 0$

$\Phi_2(\vec{x}) = (1, x_1, \cancel{x_2}, \cancel{x_1 x_2})$ $\rightsquigarrow 0$ $\rightsquigarrow 0$

ZA NAŠE PRIMJERE

BILO ŠTA SA x_2 NE NOSI NIKAKU DODATNU INFORMACIJU

X **A** $LR + \phi_1$ → PRIMJENJUJEMO LR NA PROBLEM KOJI JE U PROSTORU ZNAČAJKI $\Phi(\vec{x})$ LINEARNO ODVOJIV BEZ REGULARIZACIJE ILI OGRANIČENJA ITERACIJA TO NIKAD NEĆE KONVERGIRAT

Pj **B** $LR + \phi_2$ → LR NA LINEARNOJ KOJI NE KONVERGIRA NI

X **C** $P + \phi_0$ → PERCEPTRON I LINEARNO NEODVOJIVI PRIMJERI → NE KONVERGIRA

X **D** $P + \phi_2$ → ISTA STVAR

EFEKTIVNO:

$\Phi_0(\vec{x}) = \Phi_2(\vec{x}) = (1, x_1)$ → OSTAJE ISTO KAO I GORE

$\Phi_1(\vec{x}) = (1, x_1, x_1^2)$

→ ZA NAŠE PRIMJERE

→ U PROSTORU ZNAČAJKI NA Φ_1

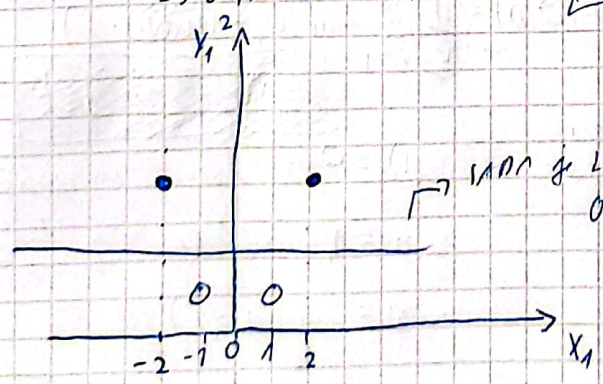

SADA JE LINEARNO ODVOJIVO

E SAD A DRUGE STRANE:

LOGISTIČKA REGRESIJA

ALI NIJE REGULARIZIRANA

NEĆE KONVERGIRATI ZA LINEARNO ODVOJIVE PROBLEME. (BEZ REGULARIZACIJE)

MODEL PERCEPTRONA KONVERGIRA SAMO ZA LINEARNO ODVOJIVE PRIMJERE.

ALI PRIMJERI NISU LINEARNO ODVOJIVI

ONDA NEĆE NIKAD STATI ALGORITAM PERCEPTRONA

SAM OD SEBE JI NE KONVERGIRA

(P) ŠTO ZNAČI DA JE $E(\vec{w}|D)$ KONVEKSNA?

→ DOĆI DO MINIMALNE VRIJEDNOSTI ILI STATI A PAROM!

(P) PITAT PROFESORA ZA KONVERGENCIJU TEŽINA I KONVERGENCIJU EMPIRIJSKE POGREŠKE

6.2 IMAMO L2 REGULARIZIRANU LOGISTIČNU REGRESIJU

↳ KORISTIMO STOHASTIČNI GRADIJENTNI SPUST

$\lambda = 1000$

$\eta = 0.01$

$X \in \mathbb{R}^2, n=2$

$\Phi(x) = (1, x_1, x_2, x_1 \cdot x_2)$

$\vec{w}_{STARI} = (0.2, 0.5, -1.1, 2.7)$

$$\vec{w} \leftarrow \vec{w}\overset{\text{ALI NE Z } w_0}{(1-\eta\cdot\lambda)} - \eta \cdot \nabla_{\vec{w}} L(y, h, \ldots$$

tj.

$$\vec{w} \leftarrow \vec{w}(1-\eta\cdot\lambda) - \eta\cdot(h(\vec{x};\vec{w}) - y)\cdot\Phi(\vec{x})$$

za $(\vec{x}, y) = ((-1,2), 1)$

$$\vec{w}_{NOVI} \leftarrow \begin{bmatrix} 0.2 \\ 0.5 \\ -1.1 \\ 2.7 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ -9 \\ -9 \\ -9 \end{bmatrix} - 0.01 \cdot -0.9996 \cdot \Phi(x)$$

$$\boxed{h(\vec{x};\vec{w}) = \frac{1}{1+e^{-z}}}$$

$z = \vec{w}^T \cdot \Phi(x)$

$$\vec{w}_{NOVI} \leftarrow \begin{bmatrix} 0.2 \\ -4.5 \\ 9.9 \\ -24.3 \end{bmatrix} + 9.96 \times 10^{-3} \cdot \Phi(x)$$

$\vec{x} = (\overset{x_1}{-1}, \overset{x_2}{2})$

$$\boxed{\Phi(\vec{x}) = (\overset{1}{1}, \overset{x_1}{-1}, \overset{x_2}{2}, \overset{x_1 \cdot x_2}{-2})}$$

$h(\vec{x};\vec{w}) = 3.706 \times 10^{-4}$

$(h(\vec{x};\vec{w}) - y) = -0.9996$

$$\vec{w} \leftarrow \begin{bmatrix} 0.2 \\ -4.5 \\ 9.9 \\ -24.3 \end{bmatrix} + \begin{bmatrix} 9.96\times10^{-3} \\ -9.96\times10^{-3} \\ 0.01996 \\ -0.01996 \end{bmatrix}$$

$$\vec{w}_{NOVI} = \begin{bmatrix} 0.2099 \\ -4.50996 \\ 9.9 \\ -24.31996 \end{bmatrix}$$

$\Delta w_1 = w_{NOVI} - w_{STARI}$

$\Delta w_1 = -4.51 - 0.5$

$\boxed{\text{Rj: } \boxed{C} \quad \boxed{\Delta w_1 = -5.01}}$

$\boxed{\text{tj. } \Delta w_1 \approx -5}$

FRAN GALIĆ, 0036604084 ; Fran Galić

$\boxed{7.1}$

$h = 2$

$X = \mathbb{R}^{100}$, $n = 100$

ϕ_j

$\phi_{0j}(x) = 1$

$$h(x) = \sigma\left(\sum_{j=0}^{5} w_j \phi_j(x)\right)$$

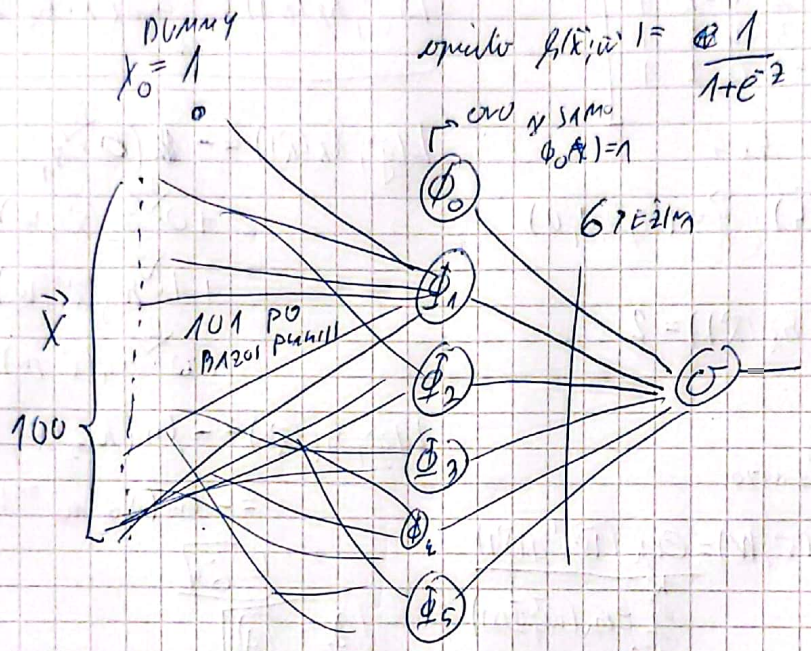

DUMMY
$x_0 = 1$
$\vec{x}$
100
101 PO BAZOI PUNITI
OVO NI SIMO $\phi_0(x) = 1$
ϕ_0
ϕ_1
ϕ_2
ϕ_3
ϕ_4
ϕ_5
6 TEŽINA
σ

općenito $h(\vec{x}; \vec{w}) = \frac{1}{1+e^{-z}}$ $\quad z = \vec{w}^T \vec{x}$

70 IMA 101

SVE ZAJEDNO: $101 \cdot 5 + 6 = 505 + 6 = \boxed{511}$

Pj :D

FRAN GALIĆ ; 0036546884 ; Fran Galić

$\boxed{9.2}$

$k = 4$

$X = \mathbb{R}^2, \; n = 2$

$\phi(\vec{x}) = (1, x_1, x_2, x_1 \cdot x_2)$

KORISTIMO GRADIJENTNI SPUST

$$W = \begin{array}{c} \text{VO} \\ \begin{bmatrix} 3 & -1 & -1 & 2 \\ 2 & -4 & -2 & 1 \\ 3 & -4 & 6 & 1 \\ -3 & 0 & 2 & 1 \end{bmatrix} \end{array}$$

4×4

$\vec{x} = (\overset{x_1}{2}, \overset{x_2}{-4})$; $\vec{y} = (0, 0, 1, 0)$

$\phi(\vec{x})^T = (1, 2, -4, -8)$

$L(\vec{y}, h_k(\vec{x})) = ?$

$$\boxed{L(\vec{y}, h_k(\vec{x})) = -\sum_{k=1}^{4} y_k^i \ln h_k(\vec{x}^i; W)}$$

$L(\vec{y}, h_k(\vec{x})) = -(0 \cdot \ln h_1(\vec{x}^i; W)$
$+ 0 \cdot \ln h_2(\vec{x}^i; W)$
$+ 1 \cdot \ln h_3(\vec{x}^i; W)$
$+ 0 \cdot \ln h_4(\vec{x}^i; W)$

$L(\vec{y}, h_k(\vec{x})) = -\ln(h_3(\vec{x}^i; W))$
$= -\ln(1{,}6 \cdot 10^{-28})$
$\boxed{= 64}$

$\boxed{\text{Rj: } \boxed{A}}$

$\cancel{W^T \cdot \Phi \neq}$

OPĆENITO

$$h_k(\vec{x}; W) = \frac{\exp(\vec{w}_k^T \phi(\vec{x}))}{\sum_{j=1}^{K} \exp(w_j^T \Phi(x))}$$

$$W^T \cdot \Phi(\vec{x}) = \begin{bmatrix} 19 \\ 7 \\ -45 \\ -8 \end{bmatrix}$$

4×4

TOSU LOGITI